

L30 BAS AI インシデントレビュー様式

不可逆化前の文明境界インシデントレビュー | v1.0

目的

目的：この様式は、LUMINA-30 の境界条件に基づいて AI インシデントをレビューするために使用する。中心となる問いは、不可逆的影響の前に人間の拒否権が実効的に残っていたかである。

使用順

- [] インシデントの文脈と範囲を記録する。
- [] 時系列と証拠を再構成する。
- [] L30-BX-01～L30-BX-04 を確認する。
- [] インシデントレビュー 1～12 を記録する。
- [] L30-CI を判定し、L30-OUT-01 を記録する。

重要注記

この文書は記述的・非拘束的な実務様式である。法令適合、安全認証、展開承認、リスク不存在を意味しない。

レビュー文脈

レビュー ID	日時
インシデント名	発生日
対象システム	レビュー担当
組織	BAS 版 / 参照元
主な使用者	事故種別
致命度	影響範囲
担当範囲	レビュー範囲
証拠資料一式	記録保全状態
レビュー担当の役割	経験区分
主な使用者 / 関係者	使用言語
独立した人間レビュー担当	証拠充足性

致命度：小 / 中 / 大。影響範囲：研究環境 / 組織内システム / インフラ系 / 外部環境。担当範囲：運用主体 / 提供者 / 組織 / 監督機関 / 不明。

インシデント概要

1. インシデント概要

何が起きたか、どのように検知されたか、最初に観測された影響を記録する。

何が起きたか	運用上の事実として簡潔に記録する。
検知経路	どのように最初に検知されたか。
初期システム挙動	検知前・検知中・検知後に観測された挙動。
初期影響	影響を受けた人、システム、環境。

証拠 / メモ / 判断理由

2. 事故分類

責任や結果を評価する前に、事故の種類を分類する。

☐ 自律研究システム	研究エージェント、実験自動化、モデル駆動探索。
☐ 自己改善 / 再帰的改良の試行	自己改善、自己変更、能力成長フィードバック。
☐ ツールチェーン拡張	ツール、API、エージェント、プラグイン、自動化連鎖による拡張。
☐ インフラ相互作用	電力、通信、物流、金融、医療、制度システムとの相互作用。
☐ 自律運用行動	人間の逐次制御外でのシステム行動。
☐ その他	分類理由を記録する。

証拠 / メモ / 判断理由

3. システム能力プロファイル

システムの能力、自律性、外部ツール、権限、運用範囲を記録する。

モデル / システム種別	モデル種別、エージェント種別、自動化層、ハイブリッド構成。
学習 / 更新方式	固定、継続、強化学習、自己教師あり、ハイブリッド、不明。
外部ツールアクセス	なし / 制限あり / 広範 / 不明。具体的ツールを記録する。
環境との相互作用	シミュレーションのみ / デジタルインフラ / 物理システム / 外部サービス。
権限と実行速度	権限レベル、自動化速度、展開頻度。

証拠 / メモ / 判断理由

4. 制御および監督構造

不可逆的影響の前に、誰が監督・停止・拒否・延期・上書きできたかを確認する。

人間監督体制	直接監督 / 定期監督 / 事後監視 / 実効的監督なし。
介入可能性	即時停止 / 遅延介入 / 間接制御のみ / 信頼できる制御なし。
意思決定権限	人間承認必須 / 助言のみ / システム自律 / 不明。
拒否地点	どこで人間の拒否が結果を変えられたか。
監査可視性	ログ、承認、システム行動が独立に確認可能だったか。

証拠 / メモ / 判断理由

L30-BAS 境界チェック

最終判断の前にこの欄を完了する。証拠が不足する場合、またはAI のみの閉ループ自己評価に依存する場合は「無効（確認不能）」を使用する。

Code	確認項目	証拠 / メモ	結果
L30-BX-01	まだ不可逆前だったか。	時系列、展開状態、実行境界、巻き戻し可能性。	☐ 満たす ☐ 満たさない ☐ 確認不能
L30-BX-02	不可逆的影響の前に、人間の拒否権は実効的に残っていたか。	誰が停止・拒否・延期・上書きできたか。それは形式だけでなく実効的だったか。	☐ 満たす ☐ 満たさない ☐ 確認不能
L30-BX-03	境界条件を確認できるだけの証拠はあるか。	時系列記録、拒否・停止記録、システムログ、監査ログ、独立した人間レビュー記録。	☐ 満たす ☐ 満たさない ☐ 確認不能
L30-BX-04	LUMINA-30 の境界条件上、手続的有効性を確認できるか。	BX-01～BX-03 を満たさない、または確認不能の場合、拒否権が保全されていたものとして扱わない。	☐ 満たす ☐ 満たさない ☐ 確認不能

境界証拠メモ / L30-OUT-01 下書き

5. 不可逆境界評価

システムが不可逆境界に接近または到達したかを評価する。

外界への不可逆的影響	なし / 可能性 / 観測済み。具体的な外界影響を記録する。
人間の最終判断権の喪失	喪失なし / 部分的低下 / 実効的喪失。
自律能力の拡張	拡張なし / 制御された拡張 / 無制限の拡張。
巻き戻し可能性	実質的巻き戻し / 形式のみ / 不可 / 不明。
$H > C(t)$	該当時点で人間介入能力が AI 増幅能力を上回っていたか。

証拠 / メモ / 判断理由

6. 制度的責任構造

責任と制御権限が連続的かつ特定可能だったかを記録する。

責任主体	システムまたはプロセスに責任を持つ機関。
運用管理主体	該当時点で運用管理権限を持っていた者。
監督機関	独立した監督機関が関与していたか。
責任連続性	明確 / 部分的 / 未定義。
責任ギャップ	委託、外注、自動化、委任によって曖昧になった箇所。

証拠 / メモ / 判断理由

7. 介入可能性評価

形式ではなく実務上、人間による有効な介入が可能であったかを評価する。

停止可能性	即時 / 遅延 / 無効 / 仕組みなし。
運用封じ込め	完全 / 部分的 / なし / 不明。
介入時間	人間判断に十分な時間があったか。
介入権限	該当者が実際に停止または延期できたか。
介入経路の証拠	介入がどのように機能するかを示す記録があるか。

証拠 / メモ / 判断理由

8. 事故結果

結果、システム状態、影響範囲、未解決の挙動を記録する。

システム状態	制御停止 / 巻き戻し / 調査中 / 未解決挙動。
影響範囲	研究 / 組織内 / インフラ / 外部環境。
人への影響	職員、利用者、患者、市民、運用者、影響集団。
運用影響	サービス停止、意思決定連鎖、展開変更、インフラ影響。
証拠状態	完全 / 部分的 / 欠落 / 争いあり。

証拠 / メモ / 判断理由

9. 構造的教訓

根拠のない責任断定を避け、事故で明らかになった構造的弱点を特定する。

監督上の弱点	どの監督機構が機能しなかった、遅れた、または存在しなかったか。
介入上の弱点	どの停止、延期、上書き、拒否経路が不十分だったか。
証拠上の弱点	どの記録が欠落、確認不能、AI 依存だったか。
エスカレーション経路	事前に特定されていなかった経路。
再発可能性	同じ構造が他所で再発し得るか。

証拠 / メモ / 判断理由

10. 事故後安定化措置

通常運用再開前に、即時安定化と証拠保全措置を記録する。

運用停止 / 制限	影響機能を停止または制限したか。
システム構成レビュー	構成、ツールアクセス、権限、展開経路を見直したか。
監督体制の再構成	レビュー権限、承認経路、エスカレーション経路を変更したか。
独立監査	独立レビューを開始したか。
48 時間安定化記録	初期安定化期間に保全、凍結、隔離したもの。

証拠 / メモ / 判断理由

11. 文明境界レビュー

人間判断、責任、介入が構造的に迂回され得る条件が明らかになったかを検討する。

人間判断の迂回	システムまたはプロセスが実質的な人間判断を迂回できたか。
責任主体の断絶	システム、チーム、提供者、機関の間で責任が断絶したか。
介入不能状態	介入が不可能または象徴的になった時点があったか。
境界警告	不可逆化前の境界警告を示したか。
将来参照	将来のレビュー担当者が最初に確認すべきこと。

証拠 / メモ / 判断理由

最終評価出力：L30-CI

[] L30-CI = 有効	BX-01、BX-02、BX-03、BX-04 のすべてを満たす場合のみ使用する。
[] L30-CI = 無効	境界条件を満たさないことが確認できる場合に使用する。
[] L30-CI = 無効（確認不能）	証拠欠落、記録不足、AI のみの閉ループ自己評価に依存する場合に使用する。

有効とは、LUMINA-30 の境界条件上の有効性のみを意味する。法令適合、安全認証、展開承認、リスク不存在を意味しない。

L30-OUT-01 要約所見

12. レビュー分類

[] [] 技術事故	技術的故障またはシステム不具合が中心である。
[] [] ガバナンス不全	判断、監督、承認、責任構造が機能しなかった。
[] [] 構造的監督ギャップ	監視、拒否、証拠、エスカレーション処理の欠落が判明した。
[] [] 境界条件警告	不可逆化前の人間拒否権の実効性喪失を示す可能性がある。

分類理由

レビュー確認

レビュー担当者

組織

役割

レビュー日

署名

この様式は記述的・非拘束的である。BAS 版/参照元はレビュー文脈欄に記録する。